

MATERIAL DOCENTE EN ABIERTO

Big Data Processing II

Guía de estudio

Máster Universitario en Análisis de Datos Deportivos

Curso 2026–2027 · 3 ECTS · segundo semestre

Equipo docente

Alberto Fernández Isabel · profesor responsable

Natalia Madrueño Sierro

Rubén Rodríguez Fernández

© 2026 Alberto Fernández Isabel, Natalia Madrueño Sierro y Rubén Rodríguez Fernández.
Algunos derechos reservados.

Licencia: [Creative Commons Atribución–CompartirIgual 4.0 Internacional \(CC BY-SA 4.0\)](https://creativecommons.org/licenses/by-sa/4.0/)

1. Finalidad y alcance

Esta guía organiza el trabajo recomendado para seguir Big Data Processing II mediante los materiales docentes del repositorio. Traduce el temario oficial en una secuencia de estudio que integra teoría, ejercicios, programas y trabajo personal, sin sustituir la guía docente ni las indicaciones del equipo docente.

La asignatura profundiza en el procesamiento distribuido y en tiempo real de datos deportivos, la optimización de pipelines y la integración responsable de inteligencia artificial generativa. Su enfoque es aplicado: cada bloque culmina en decisiones de diseño, implementación, evaluación o comunicación técnica.

Edición y estado de los materiales

Esta edición se basa en la guía docente oficial publicada el 7 de julio de 2026 y en los materiales disponibles en el repositorio a 30 de septiembre de 2026. Las presentaciones de los seis temas están incorporadas. Las fuentes LaTeX de los temas 5 y 6 son reconstrucciones documentadas a partir de sus PDF, no los originales de autor.

2. Mapa general de materiales

Tema	Bloque	Teoría	Práctica / aplicación
1	Procesamiento distribuido	Presentación · 66 diapositivas	Notebook de streaming y solución
2	Streaming en tiempo real	Kafka · 44; Spark · 60 diapositivas	2 enunciados; Kafka, Docker, PySpark y datos
3	Optimización y escalabilidad	Presentación · 36 diapositivas	Análisis y diseño de pipelines
4	IA generativa	3 presentaciones · 120 diapositivas	3 hojas de ejercicios; RAG y agentes
5	Proyectos integrados	Presentación · 46 diapositivas	Ejercicio Text-to-SQL con Spark y LangGraph
6	Tendencias y futuro	Presentación · 40 diapositivas	Análisis crítico, ético y legal

3. Resultados de aprendizaje y método de uso

La guía docente vincula la asignatura con resultados de aprendizaje relacionados con el trabajo interdisciplinar, el autoaprendizaje, la comunicación técnica, la implantación y optimización de tecnologías Big Data, la automatización y la adaptación de tendencias como el análisis en tiempo real y la inteligencia artificial.

Resultados que vertebran el itinerario

Resultados	Eje	Evidencia esperada
COM1 · COM4	Colaborar y comunicar	Trabajo en equipo, memoria técnica y exposición oral.
COM3	Aprender de forma autónoma	Contrastar documentación y fuentes científicas actuales.
COM6 · COM7	Construir soluciones Big Data	Ingesta, procesamiento, almacenamiento y optimización.
COM11 · COM12	Automatizar y adaptar tendencias	Streaming, IA generativa, RAG y agentes.
CON4 · CON8	Seleccionar tecnologías	Comparar plataformas, arquitecturas y metodologías a escala.
HAB1 · HAB4	Resolver problemas deportivos	Diseñar soluciones aplicadas, innovadoras y justificadas.

Secuencia recomendada para cada bloque

1. Leer los objetivos del tema y activar los conocimientos previos necesarios.
2. Estudiar la presentación o material teórico, anotando conceptos, decisiones y dudas.
3. Ejecutar o inspeccionar los ejemplos de código antes de modificar sus parámetros o entradas.
4. Resolver la actividad práctica y justificar las decisiones adoptadas con evidencias reproducibles.
5. Sintetizar lo aprendido en un esquema, informe breve o explicación técnica dirigida a un stakeholder.
6. Comprobar la lista de autoevaluación y registrar los aspectos que requieren tutoría o repaso.

Integridad académica y uso de IA

En actividades evaluables, las herramientas basadas en inteligencia artificial solo pueden utilizarse cuando el enunciado o el profesorado lo autoricen expresamente y dentro de los usos indicados. En el estudio autónomo deben emplearse de forma ética, legal, honesta y transparente.

Tema 1. Procesamiento de Big Data en entornos distribuidos

Bloque introductorio que conecta el análisis deportivo en vivo con la evolución desde el procesamiento batch hacia arquitecturas distribuidas y orientadas a eventos.

Objetivos de trabajo

- Comprender la transición de batch a streaming en analítica deportiva.
- Distinguir mensajería distribuida, motores de procesamiento y almacenamiento.
- Relacionar arquitecturas Lambda y Kappa con requisitos de latencia y consistencia.
- Justificar decisiones de diseño para casos de uso deportivos en vivo.

Materiales

- BDP11_Tema_01_Procesamiento_Big_Data_Distribuido.pdf.
- streaming.ipynb y streaming_soluciones.ipynb.
- Bibliografía básica de la guía docente: Gama (2010) y Marz & Warren (2015).

Plan de trabajo recomendado

1. Revisar la evolución del análisis deportivo y distinguir dato histórico, microbatch y streaming.
2. Construir un mapa de fuentes, broker, procesamiento y destinos para un caso deportivo.
3. Comparar arquitecturas Lambda y Kappa atendiendo a complejidad, latencia y reprocesamiento.
4. Ejecutar o inspeccionar el notebook y contrastar el procesamiento directo con el incremental.
5. Redactar una decisión de arquitectura indicando requisitos, supuestos y riesgos.

Trabajo personal recomendado

Proponer una arquitectura de alto nivel para monitorizar carga o fatiga durante una competición y explicar por qué la información pierde valor si llega tarde.

Tema 2. Procesamiento de flujos de datos en tiempo real

Bloque aplicado a la ingestión y al procesamiento continuo con Apache Kafka y Spark Structured Streaming, utilizando telemetría deportiva simulada.

Objetivos de trabajo

- Explicar productores, consumidores, topics, particiones, offsets y grupos de consumo en Kafka.
- Diseñar un flujo tolerante a fallos y escalable para eventos deportivos.
- Aplicar Structured Streaming con DataFrames, ventanas y tiempo de evento.
- Razonar sobre latencia, estado, watermarks y modos de salida.

Materiales

- BDPPII_Tema_02_Apache_Kafka.pdf.
- BDPPII_Tema_02_Spark_Structured_Streaming.pdf.
- Enunciados de Apache Kafka y Spark Structured Streaming.
- producer.py, sensores_deportivos_fatiga.csv, docker-compose.yml y spark_streaming.ipynb.

Plan de trabajo recomendado

1. Estudiar Kafka y representar el recorrido de un evento desde el productor hasta sus consumidores.
2. Resolver el enunciado de Kafka utilizando la descripción del conjunto de datos de sensores.
3. Estudiar Structured Streaming y distinguir tiempo de proceso de tiempo de evento.
4. Levantar o inspeccionar el entorno Docker y completar el notebook de streaming.
5. Probar ventanas, agregaciones y tolerancia a datos tardíos; documentar las salidas observadas.
6. Comparar los resultados con los requisitos del caso y proponer ajustes de particionado y recursos.

Trabajo personal recomendado

Entregar una traza reproducible de un flujo Kafka–Spark y explicar cómo se preservan orden, escalabilidad y utilidad temporal de la información.

Tema 3. Optimización y escalabilidad de pipelines deportivos

Bloque centrado en diagnosticar cuellos de botella y convertir un prototipo funcional en un pipeline eficiente, observable y desplegable.

Objetivos de trabajo

- Identificar costes de particionado, shuffle, serialización, estado y almacenamiento.
- Aplicar paralelización, caching y elección de particiones con criterio.
- Utilizar métricas y herramientas de monitorización para formular hipótesis.
- Comparar alternativas de despliegue on-premises y cloud.

Materiales

- BDPII_Tema_03_Optimizacion_Escalabilidad.pdf.
- Pipelines y ejercicios construidos en los temas 1 y 2.
- Bibliografía básica: Karau, Polak & Warren (2026), High Performance Spark.

Plan de trabajo recomendado

1. Representar el pipeline de ingestión, procesamiento, almacenamiento y consumo.
2. Localizar operaciones costosas y proponer métricas antes de modificar la configuración.
3. Evaluar particionado, skew, shuffles, caching y paralelismo con ejemplos concretos.
4. Definir un experimento controlado con línea base, cambio aislado y criterio de éxito.
5. Documentar el compromiso entre coste, latencia, rendimiento y mantenibilidad.

Trabajo personal recomendado

Preparar una ficha de diagnóstico con síntoma, evidencia, hipótesis, intervención y métrica de verificación para un pipeline deportivo en streaming.

Tema 4. Inteligencia Artificial Generativa aplicada a Big Data Deportivo

Bloque en tres sesiones: control del comportamiento mediante prompting y post-training; control de la información mediante RAG; y control del flujo y la acción mediante agentes, tools y arquitecturas cognitivas.

Objetivos de trabajo

- Explicar las capacidades y límites de un LLM en un sistema de datos deportivo.
- Diseñar prompts evaluables y reconocer cuándo el prompting no resuelve la falta de información.
- Construir conceptualmente un flujo RAG y evaluar recuperación y respuesta.
- Distinguir workflow, agente, skill y tool; controlar coste, seguridad y trazabilidad.

Materiales

- Sesión 1: Prompt Engineering y Post-training; ejercicios asociados.
- Sesión 2: Retrieval-Augmented Generation (RAG); ejercicios y RAG_1.py / RAG_1_comentado.py.
- Sesión 3: Sistemas basados en agentes; ejercicios y tres programas de workflows/agentes.
- requirements.txt y bibliografía básica: Hu et al. (2025), Hands-on LLM-based Agents.

Plan de trabajo recomendado

1. Separar generación lingüística, acceso a información, cálculo y ejecución de acciones.
2. Resolver los ejercicios de la sesión 1 y definir criterios de calidad para las respuestas.
3. Estudiar la arquitectura RAG; ejecutar o inspeccionar los ejemplos y analizar el efecto del chunking y la recuperación.
4. Estudiar agentes, estados, tools y patrones de orquestación; comparar flujo lineal y decisión autónoma.
5. Diseñar un caso deportivo indicando datos, controles humanos, registros, costes y riesgos.
6. Revisar privacidad, propiedad intelectual, sesgos y necesidad de validación experta.

Trabajo personal recomendado

Diseñar una solución que genere un informe deportivo trazable a partir de datos autorizados, separando claramente hechos recuperados, cálculos, inferencias y texto generado.

Tema 5. Proyectos integrados: del dato en tiempo real al análisis automatizado

Bloque de integración tecnológica sobre sistemas que combinan ingestión continua, cómputo en streaming, recuperación de información, agentes e interfaces conversacionales. El ejercicio Text-to-SQL aplica estos contenidos; la práctica final es una actividad evaluable transversal sobre el temario completo.

Objetivos de trabajo

- Comprender la transición desde el Business Intelligence retrospectivo hacia la analítica prescriptiva en tiempo real.
- Relacionar Kafka y Spark Structured Streaming dentro de una arquitectura completa de ingestión y procesamiento.
- Explicar cómo los flujos agénticos, las tools y el patrón ReAct conectan lenguaje natural con datos deportivos.
- Analizar el papel de RAG multimodal, la generación de narrativas y las interfaces conversacionales.

Materiales

- BDPII_Tema_05_Proyecto_Integrado.pdf · 46 diapositivas.
- Ejercicio Text-to-SQL Agent con LangGraph y Apache Spark: README, código inicial, generador de datos y dependencias.
- Materiales de los temas 1–4 como base conceptual y técnica.

Plan de trabajo recomendado

1. Estudiar el recorrido completo desde la telemetría hasta la decisión y representar los componentes del sistema.
2. Revisar particiones, semántica exactly-once, estado y watermarks en la integración Kafka-Spark.
3. Comparar workflows deterministas y agentes que consultan datos mediante tools.
4. Analizar cómo RAG multimodal y la generación de narrativas añaden contexto sin sustituir los cálculos deterministas.
5. Completar el ejercicio Text-to-SQL: generar los datos, registrar las vistas de Spark y construir el agente ReAct.
6. Validar el agente con consultas deportivas y comprobar que las respuestas se apoyan en los datos ejecutados.

Trabajo personal recomendado

Elaborar un diagrama razonado del sistema y una memoria breve del ejercicio Text-to-SQL que documente arquitectura, consultas probadas, resultados y límites del agente.

Tema 6. Tendencias y futuro del procesamiento masivo de datos en el deporte

Bloque final de análisis crítico sobre tecnologías emergentes, analítica predictiva y prescriptiva, y los retos éticos y legales del uso masivo de datos e inteligencia artificial.

Objetivos de trabajo

- Evaluar tendencias sin confundir novedad con adecuación al problema.
- Distinguir analítica descriptiva, predictiva y prescriptiva.
- Identificar impactos sobre privacidad, equidad, seguridad y responsabilidad.
- Formular recomendaciones técnicas justificadas con fuentes fiables y actuales.

Materiales

- BDPII_Tema_06_Tendencias_Futuro.pdf · 40 diapositivas.
- Guía docente oficial y bibliografía básica y complementaria.
- Documentación técnica oficial y literatura científica seleccionada por el equipo docente.

Plan de trabajo recomendado

1. Seleccionar una tendencia relevante para el análisis deportivo y delimitar el problema que pretende resolver.
2. Contrastar al menos una fuente técnica primaria y una referencia científica.
3. Analizar madurez, datos requeridos, coste, integración, explicabilidad y riesgos.
4. Distinguir predicción de recomendación y explicitar los supuestos de cualquier intervención prescriptiva.
5. Preparar una recomendación de adopción, piloto limitado o rechazo razonado.

Trabajo personal recomendado

Elaborar una nota de decisión breve para un responsable deportivo que incluya oportunidad, evidencia, riesgos ético-legales, salvaguardas y próximos pasos.

4. Planificación orientativa por unidades de trabajo

La guía docente sitúa las clases, los ejercicios, los trabajos colectivos y las tutorías entre las semanas 1 y 15. La siguiente secuencia distribuye el aprendizaje en quince unidades; cada unidad puede ocupar una o más sesiones según el calendario oficial del grupo.

Unidad	Foco	Actividad y evidencia
1	T1 · Del batch al streaming	Valor temporal del dato, arquitectura distribuida y caso deportivo.
2	T1 · Mensajería y arquitecturas	Broker, motores y comparación Lambda/Kappa; notebook de streaming.
3	T2 · Fundamentos de Kafka	Topics, particiones, productores, consumidores y contratos de eventos.
4	T2 · Kafka aplicado	Enunciado, productor y telemetría deportiva; escalabilidad y tolerancia a fallos.
5	T2 · Structured Streaming	DataFrames, ventanas, estado, watermarks y notebook PySpark.
6	T3 · Diagnóstico	Pipeline completo, métricas, particionado, shuffles y skew.
7	T3 · Producción	Caching, recursos, observabilidad y opciones on-premises/cloud.
8	T4 · Prompting	Capacidades y límites del LLM; especificación y evaluación de prompts.

Carga de trabajo

La guía docente establece 75 horas totales: 30 horas presenciales/relacionadas y 45 horas de preparación autónoma. Esta planificación debe ajustarse a las fechas y actividades concretas comunicadas por el profesorado.

4. Planificación orientativa por unidades de trabajo (continuación)

Unidad	Foco	Actividad y evidencia
9	T4 · RAG	Recuperación, chunking, vectores, trazabilidad y evaluación de respuestas.
10	T4 · Agentes	Estados, tools, workflows, costes, seguridad y supervisión humana.
11	T5 · Arquitectura integrada	Kafka, Spark, estado, RAG y agentes en un flujo de extremo a extremo.
12	T5 · Text-to-SQL	Datos sintéticos, vistas Spark SQL, tools y construcción del agente ReAct.
13	T5 · Narrativas e interfaces	RAG multimodal, validación de respuestas y visualización conversacional.
14	T6 · Tendencias	Fuentes fiables, madurez, integración, predicción y prescripción.
15	T6 · Ética, legalidad y síntesis	Privacidad, equidad, responsabilidad, límites y decisión final.

Uso de tutorías

- Llevar una pregunta concreta, el contexto mínimo y la evidencia del intento realizado.
- Diferenciar dudas conceptuales, errores de entorno, problemas de datos y decisiones arquitectónicas.
- Registrar la conclusión y convertirla en una prueba, una mejora documental o una decisión de diseño.

Trabajo en equipo

En las prácticas y en el proyecto final se recomienda distribuir responsabilidades sin fragmentar el conocimiento: cada integrante debe poder explicar el problema, la arquitectura, los datos, el código, las pruebas, los resultados y las limitaciones.

5. Relación con la evaluación

La evaluación oficial es continua. La guía docente establece tres componentes revaluables y exige una nota mínima de 5 en cada actividad. El proyecto final evalúa el temario completo y no constituye el contenido del tema 5. Las fechas concretas y cualquier ajuste deberán confirmarse siempre en Aula Virtual y con el equipo docente.

Actividad	Peso	Contenido	Evidencia	Referencia temporal
Prácticas 1 y 2	40 %	P1: temas 1–3 · P2: temas 4–6	Memoria y código	Semanas 5 y 10
Exposición oral	20 %	Temario completo	Presentación y preguntas	Fecha oficial
Proyecto final	40 %	Temario completo	Memoria y código	Semanas 13–15

Lista de comprobación de una entrega técnica

- ☐ El problema, los usuarios y los criterios de éxito están definidos.
- ☐ La procedencia, el significado y las limitaciones de los datos están documentados.
- ☐ La arquitectura y las decisiones tecnológicas se justifican frente a alternativas.
- ☐ El entorno y los pasos de ejecución son reproducibles.
- ☐ Las pruebas cubren comportamiento, rendimiento y fallos relevantes.
- ☐ Los resultados se apoyan en evidencias y separan hechos, inferencias y limitaciones.
- ☐ La memoria y la presentación citan fuentes y atribuyen correctamente contenidos de terceros.
- ☐ El equipo puede defender oralmente el trabajo y responder sobre código, datos y decisiones.

6. Localización y estado de los materiales

La carpeta material_original conserva los documentos de trabajo y sus fuentes. La carpeta material_abierto contiene exclusivamente versiones preparadas para publicación o documentación de su estado de revisión.

Material	Ubicación	Destino	Estado
Guía docente	material_original/guias	Referencia institucional	Disponible
Guía de estudio	material_abierto/00_guias	Categoría 0	Disponible
Presentaciones	material_original/teoria	Candidatas a categoría 2	Temas 1–6; auditoría pendiente
Fuentes de teoría	material_original/fuentes/teoria	Editables	Temas 1–6; las de T5–T6 son reconstrucciones desde PDF
Prácticas	material_original/practica	Candidatas a categoría 3	Temas 2, 4 y 5; proyecto final separado
Fuentes de práctica	material_original/fuentes/practica	Editables	Temas 2 y 4; proyecto final
Código y notebooks	material_original/programas	Candidatos a categoría 6	Temas 1, 2, 4 y 5; revisión pendiente

Qué significa «pendiente de publicación»

- El contenido puede utilizarse en la docencia, pero aún debe cerrarse su versión canónica.
- Deben verificarse autoría, licencia, atribuciones, fuentes de imágenes y materiales de terceros.
- Los editables y el software requieren documentación suficiente para reutilización autónoma.
- Solo las copias validadas pasarán al paquete definitivo de BURJC Digital.

Los PDF de los seis temas y el enunciado de la práctica final están incorporados. Las fuentes de los temas 5 y 6 son reconstrucciones desde PDF y están identificadas como tales. Continúa pendiente la auditoría previa a la publicación abierta.

7. Referencias y licencia

Documento de referencia

Universidad Rey Juan Carlos (2026). Guía docente de Big Data Processing II, Máster Universitario en Análisis de Datos Deportivos, curso 2026–2027. Fecha de publicación indicada en el documento: 7 de julio de 2026.

Bibliografía recogida en la guía docente

- Gama, J. (2010). Knowledge Discovery from Data Streams.
- Marz, N., & Warren, J. (2015). Big Data: Principles and Best Practices of Scalable Real-Time Data Systems.
- Hu, S., Ren, S., Chen, Y., Mu, C., Liu, J., Cui, Z., et al. (2025). Hands-on LLM-based Agents: A Tutorial for General Audiences.
- Karau, H., Polak, A., & Warren, R. (2026). High Performance Spark: Best Practices for Scaling and Optimizing Apache Spark. O'Reilly Media.
- Recursos complementarios: documentación de Apache Kafka y Apache Flink; bases de datos NoSQL; herramientas de procesamiento de texto.

Licencia de esta guía

© 2026 Alberto Fernández Isabel, Natalia Madrueño Sierro y Rubén Rodríguez Fernández. Algunos derechos reservados.

Esta guía se distribuye bajo la licencia [Creative Commons Atribución–CompartirIgual 4.0 Internacional \(CC BY-SA 4.0\)](#).

La licencia se aplica exclusivamente al contenido original de esta guía. No se extiende a materiales de terceros citados, enlazados o reproducidos, que conservan su licencia o régimen jurídico propio.

Atribución recomendada

Forma breve

Fernández Isabel, A.; Madrueño Sierro, N.; y Rodríguez Fernández, R. (2026). Big Data Processing II: Guía de estudio. Universidad Rey Juan Carlos. CC BY-SA 4.0.