

# Big Data Processing II

## IA Generativa aplicada al deporte

### Retrieval-Augmented Generation (RAG)

Alberto Fernández Isabel  
Natalia Madrueño Sierro  
Rubén Rodríguez Fernández

DSLAB

Marzo 2026





## **Material docente en abierto de la Universidad Rey Juan Carlos**

**Asignatura:** Big Data Processing II

**Titulación:** Máster Universitario en Análisis de Datos Deportivos

**Autores:** Alberto Fernández Isabel

Natalia Madrueño Sierro

Rubén Rodríguez Fernández

**Fecha:** 2026

© 2026 Equipo docente. Algunos derechos reservados. Esta obra se distribuye bajo la licencia Creative Commons Atribución-CompartirIgual 4.0 Internacional.

Los logotipos, marcas y referencias de terceros conservan su régimen jurídico propio y quedan excluidos de la licencia, salvo indicación expresa.

**Depósito institucional:** <https://burjcdigital.urjc.es>

## Mapa del bloque



## Sesión 1

### Control del comportamiento

Prompt Engineering + Post-training



## Sesión 2

### Control de la información

Retrieval-Augmented Generation (RAG)



## Sesión 3

### Control del flujo y la acción

Agentes, Tools y Arquitecturas Cognitivas

# Introducción



Un LLM modela una distribución condicional:

$$P(y \mid x)$$

donde:

- $x$  = prompt + contexto disponible
- $y$  = secuencia generada

Pero:

- No tiene acceso directo a bases de datos externas.
- No consulta sistemas internos.
- No distingue entre dato real y patrón aprendido.

**Conclusión:** conocimiento aprendido  $\neq$  acceso a información actualizada.



El Prompt Engineering:

- Controla estructura.
- Reduce ambigüedad.
- Define formato.

Pero:

*Prompting  $\nrightarrow$  Acceso a datos externos*

**No modifica la base informacional del modelo.**

## Arquitectura general de recuperación aumentada

Esquema conceptual original de la edición abierta



Un sistema real dispone de:

- Tracking físico por partido.
- Métricas avanzadas (xG, PPDA, presiones).
- Informes médicos.
- Observaciones de scouting.

Pregunta crítica:

*¿Ha disminuido la intensidad de presión tras acumular más de 300 minutos en 10 días?*

**Un LLM aislado no puede responder correctamente.**

## Definición de RAG



Retrieval-Augmented Generation introduce un mecanismo externo:

$$Output = f(Prompt + Retrieve(Query))$$

- Retrieve(Query) devuelve fragmentos relevantes.
- El LLM genera condicionado por ese contexto.

No cambia parámetros del modelo. Cambia la evidencia disponible en inferencia.



| Componente | Rol                      |
|------------|--------------------------|
| Embeddings | Representación semántica |
| Vector DB  | Indexación eficiente     |
| Retriever  | Selección de contexto    |
| LLM        | Síntesis condicionada    |

RAG es una arquitectura distribuida, no una simple extensión del modelo.

## Flujo de recuperación y generación

Esquema conceptual original de la edición abierta

## Diseño técnico de RAG



Dividir documentos implica:

- Elegir **tamaño de fragmento**.
- Definir **solapamiento**.
- Preservar **coherencia semántica**.

Errores comunes:

- Chunk demasiado grande → baja precisión.
- Chunk demasiado pequeño → pérdida de contexto.
- Solapamiento excesivo → redundancia y coste.

### Estrategias de fragmentación

Esquema conceptual original de la edición abierta



Un embedding es una función:

$$E : \text{Texto} \rightarrow \mathbb{R}^d$$

Permite medir similitud semántica.

Limitaciones:

- No captura bien relaciones numéricas exactas.
- Puede perder contexto temporal.
- Similaridad  $\neq$  relevancia estadística.



Similitud típica:

$$\text{sim}(u, v) = \frac{u \cdot v}{\|u\| \|v\|}$$

Pero:

- Similaridad semántica no garantiza pertinencia.
- Sensible a redacción del query.

La calidad del retrieval es crítica.

## Representación vectorial

Esquema conceptual original de la edición abierta



Un sistema robusto debe permitir:

- Filtrado por temporada, jugador, competición.
- Indexación por tipo de documento.
- Actualización incremental.


Sin metadatos, el retrieval pierde precisión contextual.

## **Caso de recuperación aplicado al fútbol**

Esquema conceptual original de la edición abierta



Cada etapa introduce posible error.





*Veracidad*  $\uparrow \Rightarrow$  *Coste*  $\uparrow$

- Más contexto  $\rightarrow$  más tokens.
- Más tokens  $\rightarrow$  mayor latencia.
- Mayor latencia  $\rightarrow$  menor escalabilidad.

Diseñar **RAG** es **optimizar** este equilibrio.

### Compromisos entre recuperación y generación

Esquema conceptual original de la edición abierta

## Aplicaciones en deporte



Base interna:

- Métricas por partido.
- Indicadores avanzados.
- Carga física acumulada.

Consulta:

*Compara evolución de presión alta con descanso < 72h.*

Requiere filtrado + recuperación + síntesis.

### Pipeline RAG

Esquema conceptual original de la edición abierta



Documentos:

- Informes técnicos.
- Observaciones cualitativas.

Permite:

- Búsqueda semántica.
- Detección de patrones recurrentes.
- Síntesis multi-documento.

## **Ejemplo de consulta con contexto deportivo**

Esquema conceptual original de la edición abierta



### Problema:

Embeddings no gestionan bien números exactos.

Solución:

- **Recuperación textual** (búsqueda semántica en RAG).
- **Cálculo determinista externo** (fórmulas programadas).
- **Inyección de resultados estructurados** (creación de tablas numéricas).

Arquitectura híbrida = mayor precisión.

## Limitaciones



RAG introduce dos fuentes de error:

$$Error_{total} = Error_{retrieval} + Error_{generation}$$

**Un mal retrieval no se compensa con mejor modelo.**

## Fuentes de error en RAG

Esquema conceptual original de la edición abierta



Si el documento contiene error:

- **El modelo lo amplifica.**
- **No detecta contradicciones internas.**
- **No valida consistencia factual.**

RAG mejora acceso, no garantiza verdad.

## Evaluación



- Precision@k
- Recall@k
- Mean Reciprocal Rank (MRR)
- nDCG

Sin evaluar retrieval, no se puede optimizar el sistema.

### Evaluación del flujo RAG

Esquema conceptual original de la edición abierta



Se debe medir:

- **Coherencia final.**
- **Consistencia con fuente.**
- **Estabilidad entre ejecuciones.**
- **Trazabilidad** (citar fragmentos).

RAG sin trazabilidad es **opaco** y sin estabilidad **no es confiable**.

## Conclusiones



En datos dinámicos, RAG suele ser preferible.

| <b>Fine-tuning</b>   | <b>RAG</b>            |
|----------------------|-----------------------|
| Cambia parámetros    | No cambia parámetros  |
| Integra conocimiento | Consulta conocimiento |
| Coste alto inicial   | Coste por consulta    |
| Riesgo de olvido     | Modelo intacto        |



Es una arquitectura de **acceso a información**, no un mecanismo de aprendizaje.

- RAG no hace al modelo más inteligente.
- El sistema se especializa en un contexto.
- Incrementa el tamaño del prompt.
- Afecta al número de tokens utilizados.

**Siguiente paso:** arquitecturas agénticas.



- El texto, los ejemplos y los esquemas de esta edición abierta se distribuyen bajo CC BY-SA 4.0.
- Las imágenes de procedencia no acreditada de la versión de trabajo se han retirado y sustituido por esquemas conceptuales originales.
- Los logotipos y marcas citados se utilizan únicamente con finalidad identificativa y quedan excluidos de la licencia.
- Las referencias técnicas se conservan mediante citas y enlaces a sus fuentes correspondientes.
- Información de licencia: <https://creativecommons.org/licenses/by-sa/4.0/deed.es>