

Big Data Processing II

IA Generativa aplicada al deporte

Tema 5: Proyectos integrados

Del dato en tiempo real al análisis automatizado

Alberto Fernández Isabel
Natalia Madrueño Sierro
Rubén Rodríguez Fernández

DSLAB

Abril 2026





- Comprender la transición del análisis retrospectivo (BI tradicional) a la toma de decisiones prescriptiva en tiempo real.
- Diseñar infraestructuras integradas combinando ingestión masiva (Kafka) y cómputo continuo (Spark).
- Desplegar sistemas de IA generativa y ecosistemas multiagente sobre flujos de datos deportivos.
- Implementar arquitecturas RAG multimodales para la comprensión espacio-temporal del juego.
- Automatizar la generación de informes y narrativas adaptadas a diferentes perfiles de stakeholders.



- ➊ Introducción: El paradigma del análisis automatizado
- ➋ Arquitecturas completas de ingestión y procesamiento
- ➌ Orquestación de IA Generativa y flujos agénticos
- ➍ RAG Multimodal y Generación de Narrativas
- ➎ Visualización avanzada e interfaces conversacionales
- ➏ Conclusiones

Introducción al paradigma automatizado



- La ciencia de datos deportivos ya no puede depender exclusivamente de los informes post-partido.
- El valor del dato decae exponencialmente desde el momento en que ocurre la acción.
- **Objetivo moderno:** Proveer a los entrenadores y analistas de herramientas que sugieran ajustes tácticos durante el desarrollo de la competición.
- Se exige una transición arquitectónica hacia la analítica predictiva y automatizada.



La infraestructura actual requiere la convergencia de tres pilares:

- **Ingestión continua:** Captura ininterrumpida de biometría, GPS y vídeo.
- **Motor determinista:** Cálculos estadísticos en ventanas temporales.
- **Capa cognitiva (IA):** Modelos de lenguaje que interpretan y traducen matemáticas en táctica.

Esta convergencia permite pasar de paneles de control estáticos a "**sistemas observacionales**" inteligentes.



- Un LLM tradicional es una "foto fija" probabilística basada en su entrenamiento.
- **El problema en el deporte:** Carece de contexto del estado actual del mundo; no sabe quién está fatigado ni cuál es el marcador en el minuto 75.
- **Solución:** Integrar al LLM como un motor de razonamiento (*reasoning engine*) dentro de un pipeline de datos alimentado en vivo.



- La automatización total abarca desde la captura del evento micro-táctico hasta la narrativa macroscópica.
- Requiere superar los límites epistemológicos de los enfoques batch.
- El contexto inmediato permite extraer valor competitivo en la ventana crítica de la toma de decisiones.



- ① **Fuentes (Productores):** Tracking óptico, sensores de balones, wearables.
- ② **Middleware de Mensajería:** Enrutamiento masivo y ordenado.
- ③ **Motor de Streaming:** Agregación e identificación de anomalías.
- ④ **Agentes LLM / RAG:** Generación de diagnósticos e informes.
- ⑤ **Destinos (Consumidores):** Aplicaciones de cuerpo técnico, retransmisiones (broadcasters).

Arquitecturas completas de ingestión



- Entornos de alta presión (estadios repletos) con conectividad variable.
- **Teorema CAP aplicado al deporte:**
 - Consistencia (C), Disponibilidad (A), Tolerancia a Particiones (P).
- En un partido en directo, la latencia es crítica.
- Generalmente, se prioriza la **Disponibilidad** y la **Tolerancia a fallos** de red (AP) sobre la consistencia matemática perfecta que llegaría tarde.



- Apache Kafka actúa como el núcleo de mensajería (Pub/Sub).
- **Desacoplamiento:** Los sensores (visión, GPS) no saben quién consume los datos.
- **Ventaja:** Permite que múltiples sistemas (motores de cálculo de xG, sistemas de IA generativa para alertas tácticas y bases de datos históricas) consuman el mismo evento de forma independiente y concurrente.



- Los proveedores de datos (Opta, StatsBomb) o estándares de la FIFA (EPTS) envían flujos jerárquicos.
- **Granularidad:** Un simple "pase" incluye decenas de metadatos asociados.
- La comprensión de estos esquemas JSON es vital para el diseño de bases de datos vectoriales y algoritmos analíticos.



Campo (Opta/EPTS)	Tipo	Implicación Analítica
event_id	UUID	Deduplicación semántica (exactly-once).
type_id	Entero	Filtrado en capa de ingesta (separar pases de tiros).
start_x, start_y	Flotante	Coordenadas que alimentan modelos espaciales.
timestamp	Time	Reloj del evento, crítico para latencias.
qualifiers	JSON	Contexto profundo (presión, pie débil) para enriquecer prompts de la IA.



- **Paralelismo horizontal:** El número de particiones define el rendimiento máximo.

$$\text{Particiones} = \frac{\text{Throughput total deseado}}{\text{Velocidad máxima del consumidor}}$$

- **Eficiencia:** Afinación de `batch.size` y `linger.ms` combinados con compresión (Snappy/Gzip) para reducir la carga de red.
- **Resiliencia:** Uso de `acks=all` y `enable.idempotence=true` para garantizar que ningún dato crítico (como una alerta de fatiga) se pierda o duplique.



- Se trata al flujo ininterrumpido de eventos como una tabla relacional en crecimiento perpetuo.
- Permite a los científicos de datos abstraerse de la complejidad subyacente.
- Motor de cálculo incremental para preparar métricas (ej. Posesión en el último tercio) antes de enviarlas al modelo de IA generativa.



- En un estadio, los dispositivos se desconectan y reconectan continuamente.
- Spark gestiona la semántica exactly-once usando:
 - **Write-Ahead Logs (WAL)** en sistemas distribuidos persistentes (HDFS/S3).
 - **Checkpointing distribuido:** Guarda el progreso de manera asíncrona.
- Asegura que el LLM no reciba alertas duplicadas sobre el mismo evento de juego.



- **Problema de asincronía:** El retraso entre que el jugador hace el sprint y el paquete de datos llega al servidor en la nube.
- **Watermarking:** Umbral temporal de gracia que el sistema espera antes de cerrar el cálculo de una ventana.

$$W(t) = T_{max}(t) - \Delta$$

- Garantiza que la IA analice ventanas de tiempo completas sin colapsar la memoria del servidor.



- **Desventaja de Lambda:** Mantener código dual (Speed y Batch) duplica el riesgo de error algorítmico.
- **Ventaja de Kappa para la IA:** Kafka persiste todo el historial; el motor de streaming reprocesa todo desde cero si cambia un modelo subyacente.
- Garantiza que el agente cognitivo de IA reciba distribuciones de datos y métricas idénticas, ya sea auditando un partido de 2024 o analizando el directo.

IA Generativa y flujos agénticos



- La interacción ya no es reactiva (humano preguntando a una máquina).
- Se avanza hacia arquitecturas **agénticas y orquestadas orientadas a la acción** (Agentic Workflows).
- Un agente no solo resume texto, sino que ejecuta código, consulta bases de datos vectoriales y planifica respuestas estructuradas.



- LangChain funciona como el marco orquestador.
- Interconecta el razonamiento del LLM con las capacidades deterministas de Big Data (Spark, bases de datos SQL).
- Aporta "herramientas" (Tools) al LLM para que este no invente números, sino que los busque activamente en los clústeres de datos.



Uso práctico: Un analista interroga al sistema en lenguaje natural.

- 1 El LLM usa su herramienta integrada para traducir la consulta humana a un código de consulta (Spark SQL).
- 2 Ejecuta la consulta contra el DataFrame en memoria.
- 3 Extrae el resultado numérico.
- 4 Redacta una explicación en base a ese dato duro.



Pregunta del entrenador: "¿Tasa de éxito de pase progresivo del mediocentro bajo presión en los últimos 15 min?"

- **Planner:** Descompone la consulta → Entidad (jugador), Métrica (tasa de pase), Contexto (presión alta basada en coordenadas), Filtro Temporal (15 min).
- **Executor:** Corre el SQL en Spark.
- **Synthesizer:** Valida lógicamente el 45% obtenido y genera la alerta narrativa argumentada.



- La automatización proactiva que monitorea patrones complejos sin requerir un prompt humano.
- Se utilizan máquinas de estado explícitas para enrutar decisiones.
- Compañías como **Machina Sports** ya proveen infraestructuras de IA agéntica enfocadas exclusivamente en el ecosistema deportivo, dotando a la IA de conocimiento táctico profundo y ejecución fiable.



El sistema opera en un ciclo de iteración continuo:

- ① **Think:** "Detecto una anomalía en la velocidad del jugador."
- ② **Act:** "Usaré la herramienta de historial médico para ver sus promedios."
- ③ **Observe:** "La recuperación cardíaca ha bajado un 15% respecto al mes pasado."
- ④ **Act:** "Emitiré una alerta de sustitución al cuerpo técnico."



Para garantizar estabilidad computacional frente a alucinaciones:

- **Router:** Desvía consultas puramente estadísticas hacia motores deterministas y consultas cualitativas hacia RAG.
- **Validator:** Obliga al agente a parsear su salida bajo un formato estricto (JSON), repitiendo el proceso si el formato es erróneo.
- **Loop Bounded:** Impone un máximo de "pensamientos" iterativos para evitar que el sistema agote los tokens en un bucle infinito de resolución.

RAG Multimodal y Generación de Narrativas



- Los datos tabulares solo representan una fracción de la realidad del partido.
- **RAG Multimodal:** Integrar simbióticamente flujos de vídeo HD, audio de retransmisión y telemetría estructurada.
- **Vectorización combinada:** Permite a la IA no solo buscar "tiros a puerta", sino buscar "jugadas con presión asfixiante" utilizando comprensión espaciotemporal.



- Sistemas de visión profunda analizan fotogramas y detectan la topología del juego y trayectorias.
- **Arquitecturas avanzadas (ej. GameSight):** Realizan un alineamiento en dos etapas, identificando primero las entidades visuales anónimas en el vídeo para luego enriquecerlas con metadatos y estadísticas históricas.
- Esto mejora drásticamente la calidad de los comentarios automatizados.
- Erradica la disonancia de contexto en los modelos de lenguaje genéricos.



- **Problema fundamental:** Inyectar payloads JSON crudos al contexto del LLM es ineficiente y provoca pérdida de precisión matemática (alucinaciones).
- **Solución:** Preprocesamiento determinista.
- Traducir diccionarios numéricos (`type_id = 10`, `outcome = 0`) a oraciones semánticas estructuradas antes del prompt: "El jugador X intentó una entrada pero no recuperó la posesión".

Cada vez es menos necesaria esta conversión, pero no es deseable introducir JSONs muy grandes.



- Creación de pipelines cerrados de monitorización continua de eventos para generar contenido automatizado y filtrado.
- Sistemas como **LLM-SportTweet** utilizan orquestación para leer flujos de eventos asíncronos y tomar decisiones editoriales determinando qué sucesos merecen ser convertidos en narrativas.



Antes de generar una alerta o informe, el LLM evalúa y puntúa internamente el evento táctico o la noticia:

- **Proximity:** Relevancia para el deporte/equipo analizado.
- **Freshness:** Criticidad e inmediatez del suceso.
- **Impact:** Grado de influencia en el resultado del partido.
- **Uniqueness:** Penalización de la redundancia frente a la memoria episódica a corto plazo.



- Solo si el evento supera el umbral de Scoring, el agente desencadena la generación.
- **Técnicas Few-Shot:** Forzar al modelo a adoptar un formato retórico y una longitud específica.
- Se adapta el vocabulario automáticamente:
 - **Modo Analista:** Foco estadístico en métricas de presión.
 - **Modo Aficionado:** Foco emocional y contexto histórico para redes sociales.



- La generación de narrativas en directo exige reducir la latencia al mínimo.
- Se investigan soluciones híbridas que acoplan redes neuronales convolucionales con LLMs.
- **Ejemplo:** Arquitecturas OS-CNN pre-computan y anticipan eventos cinemáticos que luego se inyectan en plantillas Prompt Engineering para modelos como LLaMA 3.3, logrando comentarios fluidos en tiempo real con latencias aptas para retransmisiones interactivas.



La fiabilidad estricta no es opcional en la élite.

Principio de Separación (Separation of Concerns):

- El LLM jamás computa matemáticas (complejas).
- El motor Spark realiza las agregaciones.
- El marco RAG localiza el dato duro.
- El LLM ingiere el dato protegido bajo el mandato estricto de "Utilice EXCLUSIVAMENTE los parámetros de la matriz".

Visualización Avanzada e Interfaces



- Los petabytes de datos son inútiles sin una democratización efectiva de los insights.
- **El paradigma 2026:** Las predicciones y gráficas estáticas previas al partido son obsoletas.
- Se demandan probabilidades recalibradas continuamente en función del flujo de eventos (e.g., probabilidades de micro-sucesos) y total transparencia analítica.



- **Cuerpo Técnico:** Resolución analítica máxima; fusión de cinemática de alta frecuencia y fisiología para prevención biomecánica de lesiones.
- **Front Office:** Proyecciones a largo plazo (impacto económico, modelado de carreras de atletas).
- **Broadcasters:** Baja latencia, inmersión rápida. Respuestas dinámicas a escenarios de tipo "What-If" para los espectadores.



- Sustitución de los paneles pasivos (Tableau, Power BI clásicos) por ecosistemas interactivos.
- La IA funciona como "científico de datos virtual permanente".
- Permite a los analistas realizar consultas declarativas profundas (e.g., "Compara nuestro índice de progresión central antes y después de la sustitución del minuto 60").



- **Problema de los Black-Boxes:** Los cuerpos técnicos no confían en índices predictivos opacos.
- La visualización debe incluir **Virtual Analyst Narratives**.
- El sistema no solo emite una probabilidad del 73%, sino que el agente detalla causalidades (e.g., métricas previas, tendencias posicionales) para justificar el número mostrado en pantalla.



- ① **Recepción:** El agente capta el pico en la gráfica.
- ② **Consulta interna:** Formula SQL y consulta el stream de datos en segundo plano.
- ③ **Recuperación RAG:** Acopla métricas actuales con cortes de vídeo del partido en curso.
- ④ **Generación de la narrativa:** Ofrece una síntesis causal explicativa en lenguaje natural para acompañar al gráfico.



- **Time-to-Insight:** Métrica fundacional en el desarrollo de paneles intra-partido.
- **Problema:** La decodificación del modelo generativo añade un retraso inherente.
- **Solución (Streaming UI):** Reducir el Time To First Token (TTFT) inyectando la respuesta palabra por palabra a la interfaz (vía WebSockets).
- Se mitiga la percepción de lentitud del usuario final de forma drástica.



- Durante la competición táctica, la fluidez del panel de control es primordial.
- Frente al teorema CAP, el diseño del panel favorece la tolerancia a la partición y la disponibilidad.
- Es preferible renderizar tendencias estimadas al instante que bloquear el dashboard a la espera de la consistencia total del evento cerrado.

Conclusiones



- El procesamiento de Big Data moderno consolida el streaming continuo con el análisis cognitivo.
- La orquestación agéntica y los RAG multimodales son las claves para dar contexto espacio-temporal a la inteligencia artificial.
- La arquitectura debe mitigar sistemáticamente las alucinaciones limitando el acceso de los modelos a datos precomputados deterministas.
- El futuro radica en visualizaciones conversacionales y proactivas que empoderen a todos los stakeholders del entorno deportivo en tiempo real.